PREPARACIÓN, LIMPIEZA Y TRANSFORMACIÓN DE DATOS (WRANGLING)

PRÁCTICAS APLICADAS DEL TEMA 2

Luis Alfonso Vásquez Pino

Leonardo Sebastian Campos Cango

Tomasa Marilu Panta Chunga

Yanela Liz Acori Sanchez

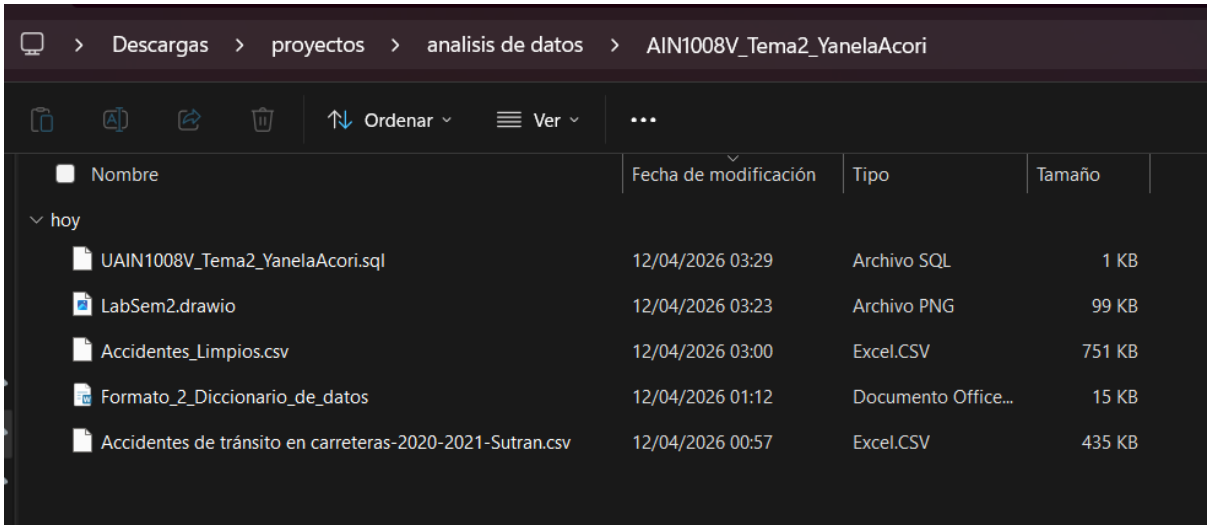
Análisis de Datos | 12/04/2026

PREPARACIÓN Y ORGANIZACIÓN DEL PROYECTO

Datos del Dataset:

Fuente	Superintendencia de Transporte Terrestre de Personas, Carga y Mercancías - SUTRAN
Fecha	2026/04/08
Licencia	Open Data Commons Attribution License

Crear carpeta:

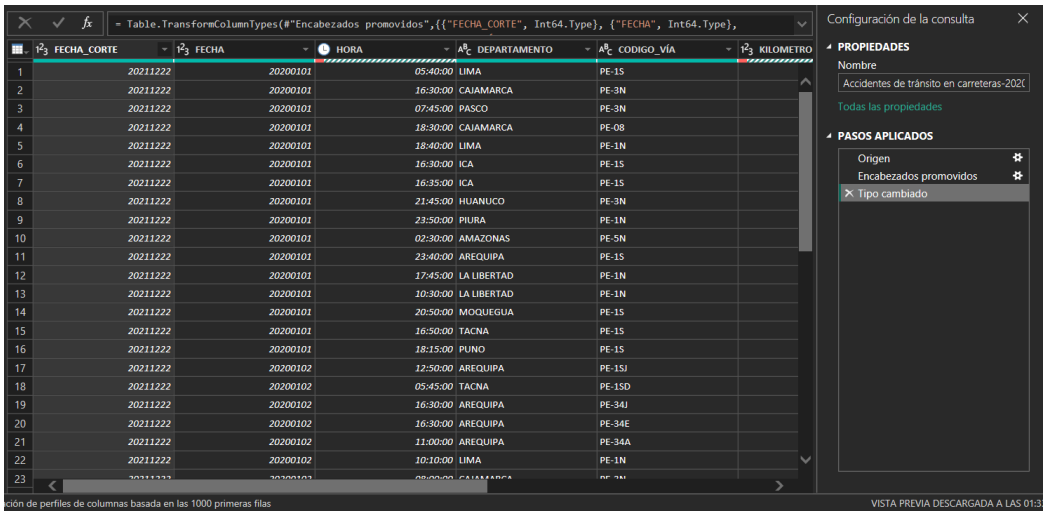


ESTANDARIZACIÓN DE FORMATOS Y TIPOS DE DATOS.

Corregir fechas, textos y tipos numéricos en al menos 3 columnas

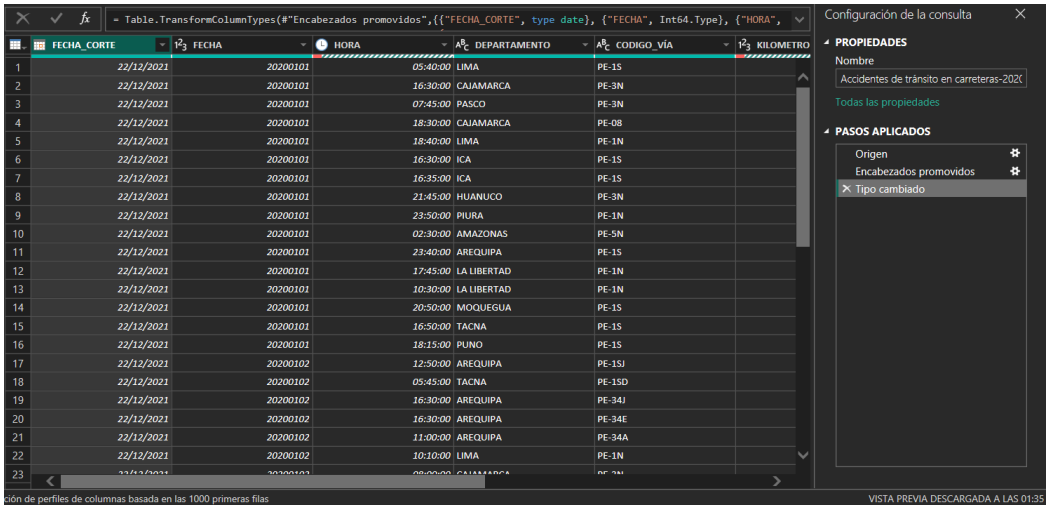
- **<u>Corrección del formato fecha:</u>**

Formato anterior; *no contenía el formato "Fecha", era formato texto:*



	FECHA_CORTE	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA	KILOMETRO
1	20211222	20200101	05:40:00	LIMA	PE-1S	
2	20211222	20200101	16:30:00	CAJAMARCA	PE-3N	
3	20211222	20200101	07:45:00	PASCO	PE-3N	
4	20211222	20200101	18:30:00	CAJAMARCA	PE-08	
5	20211222	20200101	18:40:00	LIMA	PE-1N	
6	20211222	20200101	16:30:00	ICA	PE-1S	
7	20211222	20200101	16:35:00	ICA	PE-1S	
8	20211222	20200101	21:45:00	HUANUCO	PE-3N	
9	20211222	20200101	23:50:00	PIURA	PE-1N	
10	20211222	20200101	02:30:00	AMAZONAS	PE-5N	
11	20211222	20200101	23:40:00	AREQUIPA	PE-1S	
12	20211222	20200101	17:45:00	LA LIBERTAD	PE-1N	
13	20211222	20200101	10:30:00	LA LIBERTAD	PE-1N	
14	20211222	20200101	20:50:00	MOQUEGUA	PE-1S	
15	20211222	20200101	16:50:00	TACNA	PE-1S	
16	20211222	20200101	18:15:00	PUNO	PE-1S	
17	20211222	20200102	12:50:00	AREQUIPA	PE-1SJ	
18	20211222	20200102	05:45:00	TACNA	PE-1SD	
19	20211222	20200102	16:30:00	AREQUIPA	PE-34J	
20	20211222	20200102	16:30:00	AREQUIPA	PE-34E	
21	20211222	20200102	11:00:00	AREQUIPA	PE-34A	
22	20211222	20200102	10:10:00	LIMA	PE-1N	
23						

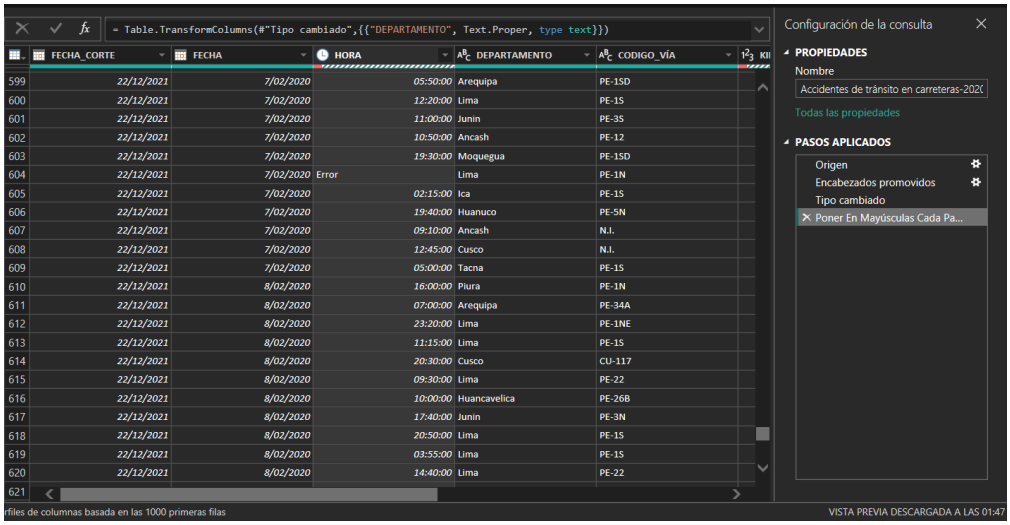
Formato nuevo; *las fechas ahora están en su formato correspondiente:*



	FECHA_CORTE	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA	KILOMETRO
1	22/12/2021	20200101	05:40:00	LIMA	PE-1S	
2	22/12/2021	20200101	16:30:00	CAJAMARCA	PE-3N	
3	22/12/2021	20200101	07:45:00	PASCO	PE-3N	
4	22/12/2021	20200101	18:30:00	CAJAMARCA	PE-08	
5	22/12/2021	20200101	18:40:00	LIMA	PE-1N	
6	22/12/2021	20200101	16:30:00	ICA	PE-1S	
7	22/12/2021	20200101	16:35:00	ICA	PE-1S	
8	22/12/2021	20200101	21:45:00	HUANUCO	PE-3N	
9	22/12/2021	20200101	23:50:00	PIURA	PE-1N	
10	22/12/2021	20200101	02:30:00	AMAZONAS	PE-5N	
11	22/12/2021	20200101	23:40:00	AREQUIPA	PE-1S	
12	22/12/2021	20200101	17:45:00	LA LIBERTAD	PE-1N	
13	22/12/2021	20200101	10:30:00	LA LIBERTAD	PE-1N	
14	22/12/2021	20200101	20:50:00	MOQUEGUA	PE-1S	
15	22/12/2021	20200101	16:50:00	TACNA	PE-1S	
16	22/12/2021	20200101	18:15:00	PUNO	PE-1S	
17	22/12/2021	20200102	12:50:00	AREQUIPA	PE-1SJ	
18	22/12/2021	20200102	05:45:00	TACNA	PE-1SD	
19	22/12/2021	20200102	16:30:00	AREQUIPA	PE-34J	
20	22/12/2021	20200102	16:30:00	AREQUIPA	PE-34E	
21	22/12/2021	20200102	11:00:00	AREQUIPA	PE-34A	
22	22/12/2021	20200102	10:10:00	LIMA	PE-1N	
23						

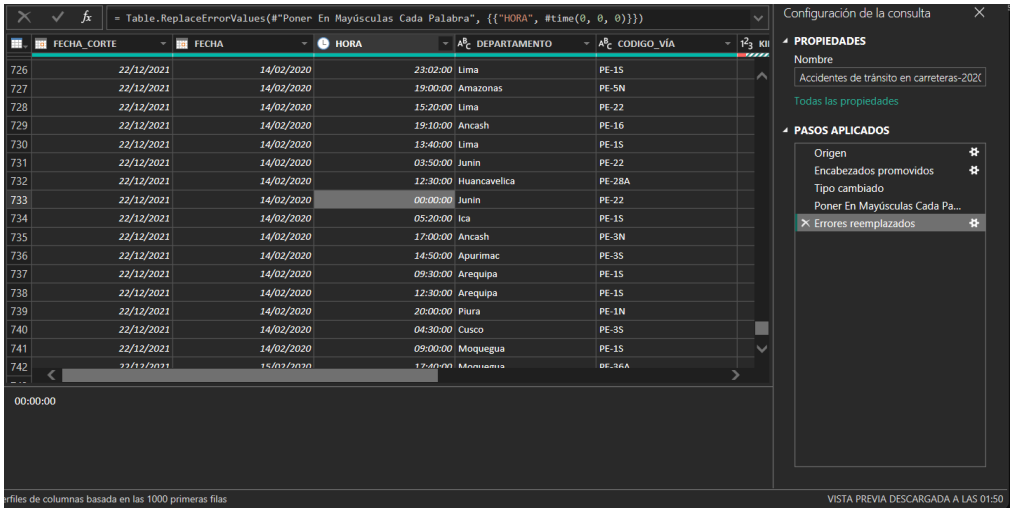
-

- **<u>Corrección del formato de la hora:</u>**
  Formato anterior; *algunas celdas presentaban la palabra "Error" debido a que eran celdas nulas y no se podían convertir al formato "Fecha"*



	FECHA_CORTE	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA
599	22/12/2021	7/02/2020	05:50:00	Arequipa	PE-1SD
600	22/12/2021	7/02/2020	12:20:00	Lima	PE-1S
601	22/12/2021	7/02/2020	11:00:00	Junin	PE-3S
602	22/12/2021	7/02/2020	10:50:00	Ancash	PE-12
603	22/12/2021	7/02/2020	19:30:00	Moquegua	PE-1SD
604	22/12/2021	7/02/2020	Error	Lima	PE-1N
605	22/12/2021	7/02/2020	02:15:00	Ica	PE-1S
606	22/12/2021	7/02/2020	19:40:00	Huanuco	PE-5N
607	22/12/2021	7/02/2020	09:10:00	Ancash	N.I.
608	22/12/2021	7/02/2020	12:45:00	Cusco	N.I.
609	22/12/2021	7/02/2020	05:00:00	Tacna	PE-1S
610	22/12/2021	8/02/2020	16:00:00	Piura	PE-1N
611	22/12/2021	8/02/2020	07:00:00	Arequipa	PE-34A
612	22/12/2021	8/02/2020	23:20:00	Lima	PE-1NE
613	22/12/2021	8/02/2020	11:15:00	Lima	PE-1S
614	22/12/2021	8/02/2020	20:30:00	Cusco	CU-117
615	22/12/2021	8/02/2020	09:30:00	Lima	PE-22
616	22/12/2021	8/02/2020	10:00:00	Huancavelica	PE-26B
617	22/12/2021	8/02/2020	17:40:00	Junin	PE-3N
618	22/12/2021	8/02/2020	20:50:00	Lima	PE-1S
619	22/12/2021	8/02/2020	03:55:00	Lima	PE-1S
620	22/12/2021	8/02/2020	14:40:00	Lima	PE-22
621					

Formato nuevo; *se reemplazaron las celdas vacías por el formato de hora "00:00:00":*

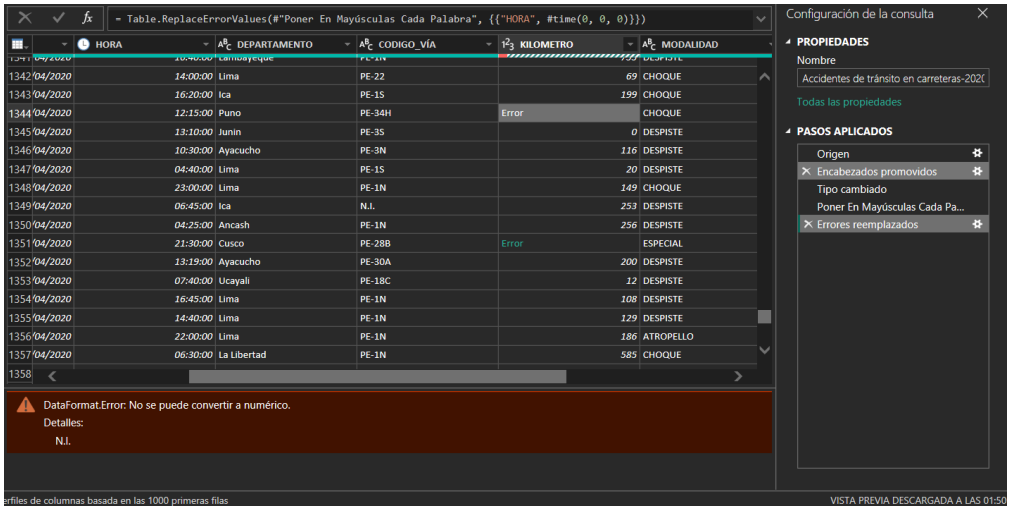


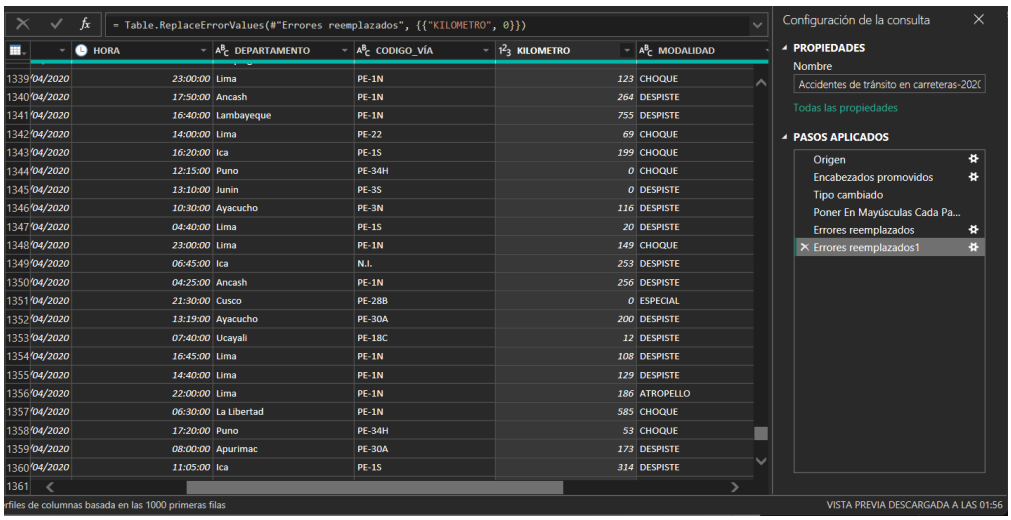
	FECHA_CORTE	FECHA	HORA	DEPARTAMENTO	CODIGO_VÍA
726	22/12/2021	14/02/2020	23:02:00	Lima	PE-1S
727	22/12/2021	14/02/2020	19:00:00	Amazonas	PE-5N
728	22/12/2021	14/02/2020	15:20:00	Lima	PE-22
729	22/12/2021	14/02/2020	19:10:00	Ancash	PE-16
730	22/12/2021	14/02/2020	13:40:00	Lima	PE-1S
731	22/12/2021	14/02/2020	03:50:00	Junin	PE-22
732	22/12/2021	14/02/2020	12:30:00	Huancavelica	PE-28A
733	22/12/2021	14/02/2020	00:00:00	Junin	PE-22
734	22/12/2021	14/02/2020	05:20:00	Ica	PE-1S
735	22/12/2021	14/02/2020	17:00:00	Ancash	PE-3N
736	22/12/2021	14/02/2020	14:50:00	Apurimac	PE-3S
737	22/12/2021	14/02/2020	09:30:00	Arequipa	PE-1S
738	22/12/2021	14/02/2020	12:30:00	Arequipa	PE-1S
739	22/12/2021	14/02/2020	20:00:00	Piura	PE-1N
740	22/12/2021	14/02/2020	04:30:00	Cusco	PE-3S
741	22/12/2021	14/02/2020	09:00:00	Moquegua	PE-1S
742	22/12/2021	15/02/2020	12:40:00	Moquegua	PE-36A

-

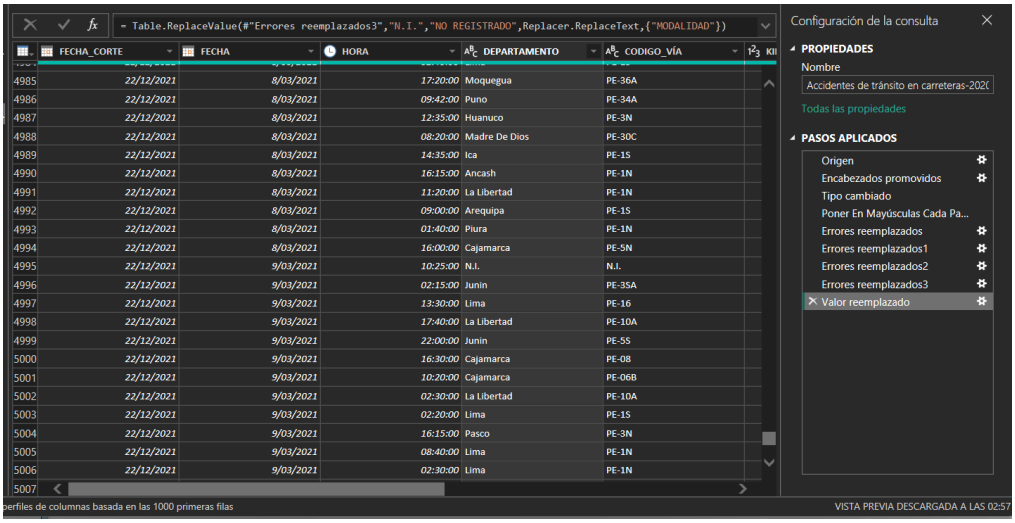
- **<u>Corrección celdas nulas o “N.I.” a 0 o “NO REGISTRADO” (dependiendo sea el caso)</u>**

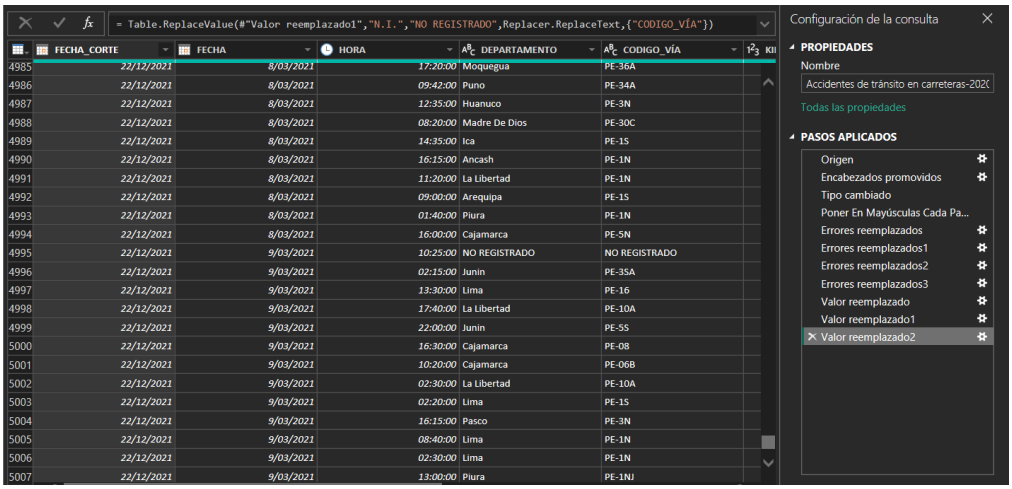
  Transformación de celdas nulas a celdas con valor 0 (entero):





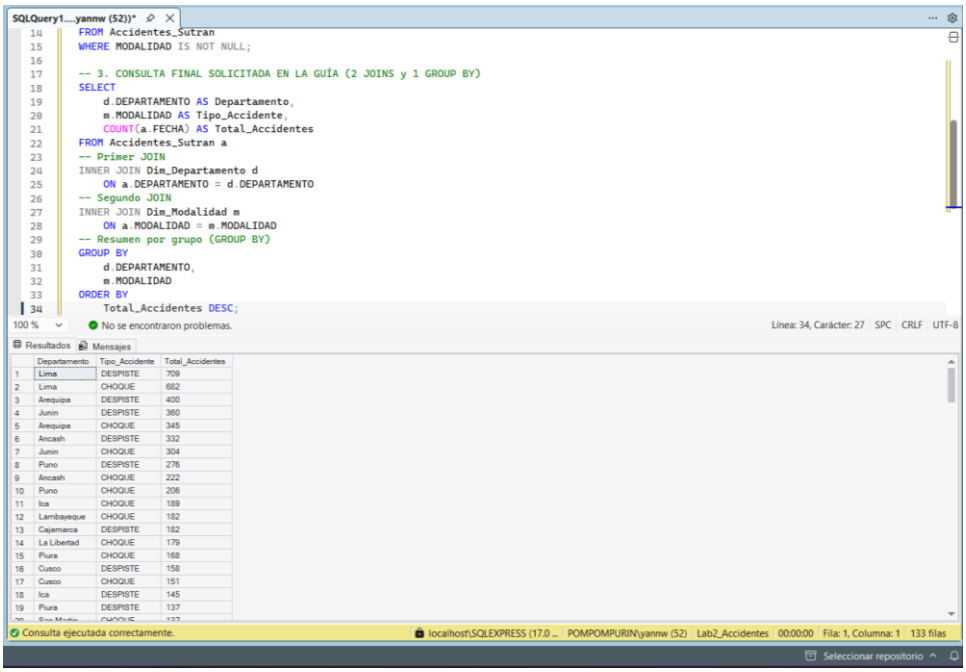
Transformación de celdas "N.I." (no nulas) a celdas con valor "NO REGISTRADO" (texto):





CONSULTA E INTEGRACIÓN DE DATOS USANDO SQL BÁSICO (SELECT/JOIN/GROUP BY).

Crear una base local, realizar 2 JOIN y 1 resumen por grupo.



```
FROM Accidentes_Sutran
WHERE MODALIDAD IS NOT NULL;

-- 3. CONSULTA FINAL SOLICITADA EN LA GUÍA (2 JOINS y 1 GROUP BY)
SELECT
    d.DEPARTAMENTO AS Departamento,
    m.MODALIDAD AS Tipo_Accidente,
    COUNT(a.FECHA) AS Total_Accidentes
FROM Accidentes_Sutran a
-- Primer JOIN
INNER JOIN Dim_Departamento d
    ON a.DEPARTAMENTO = d.DEPARTAMENTO
-- Segundo JOIN
INNER JOIN Dim_Modalidad m
    ON a.MODALIDAD = m.MODALIDAD
-- Resumen por grupo (GROUP BY)
GROUP BY
    d.DEPARTAMENTO,
    m.MODALIDAD
ORDER BY
    Total_Accidentes DESC;
```

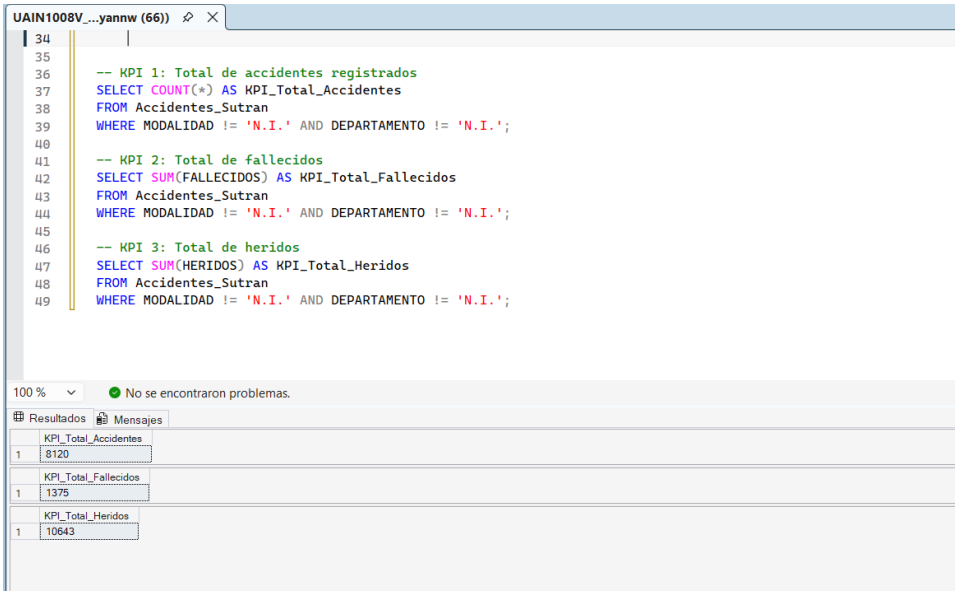
No se encontraron problemas.

	Departamento	Tipo_Accidente	Total_Accidentes
1	Lima	DESPISTE	709
2	Lima	CHOQUE	682
3	Arequipa	DESPISTE	400
4	Junin	DESPISTE	360
5	Arequipa	CHOQUE	345
6	Ancash	DESPISTE	332
7	Junin	CHOQUE	304
8	Puno	DESPISTE	276
9	Ancash	CHOQUE	222
10	Puno	CHOQUE	206
11	Ica	CHOQUE	189
12	Lambayeque	CHOQUE	182
13	Cajamarca	DESPISTE	182
14	La Libertad	CHOQUE	179
15	Piura	CHOQUE	168
16	Cusco	DESPISTE	158
17	Cusco	CHOQUE	151
18	Ica	DESPISTE	145
19	Piura	DESPISTE	137

Consulta ejecutada correctamente.

CÁLCULO DE INDICADORES BÁSICOS (KPIS).

Crear 3 KPIs y verificar su correcto cálculo.



```
-- KPI 1: Total de accidentes registrados
SELECT COUNT(*) AS KPI_Total_Accidentes
FROM Accidentes_Sutran
WHERE MODALIDAD != 'N.I.' AND DEPARTAMENTO != 'N.I.';

-- KPI 2: Total de fallecidos
SELECT SUM(FALLECIDOS) AS KPI_Total_Fallecidos
FROM Accidentes_Sutran
WHERE MODALIDAD != 'N.I.' AND DEPARTAMENTO != 'N.I.';

-- KPI 3: Total de heridos
SELECT SUM(HERIDOS) AS KPI_Total_Heridos
FROM Accidentes_Sutran
WHERE MODALIDAD != 'N.I.' AND DEPARTAMENTO != 'N.I.';
```

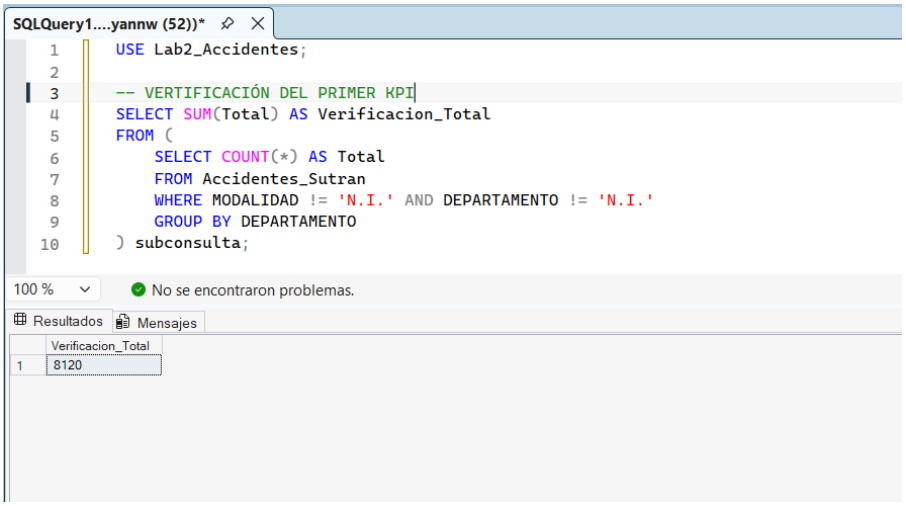
No se encontraron problemas.

	KPI_Total_Accidentes
1	8120

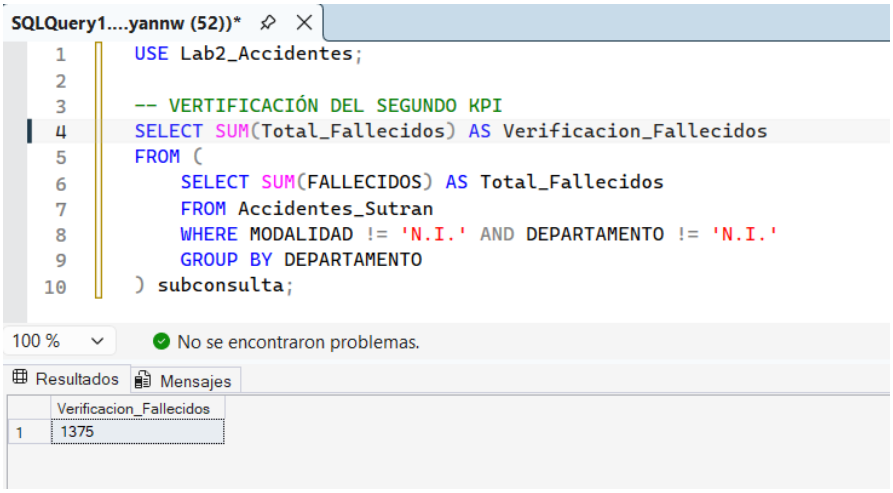
	KPI_Total_Fallecidos
1	1375

	KPI_Total_Heridos
1	10643

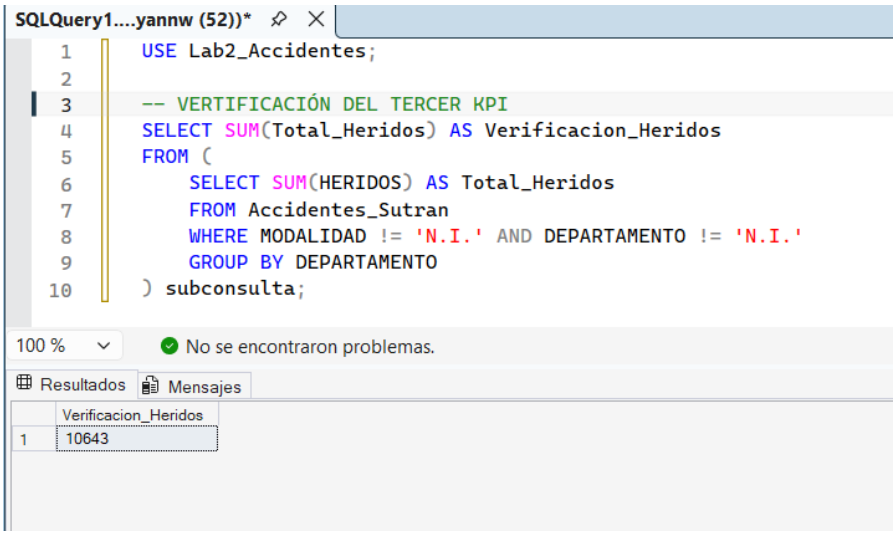
- **Verificación del primer KPI**



- **Verificación del segundo KPI**

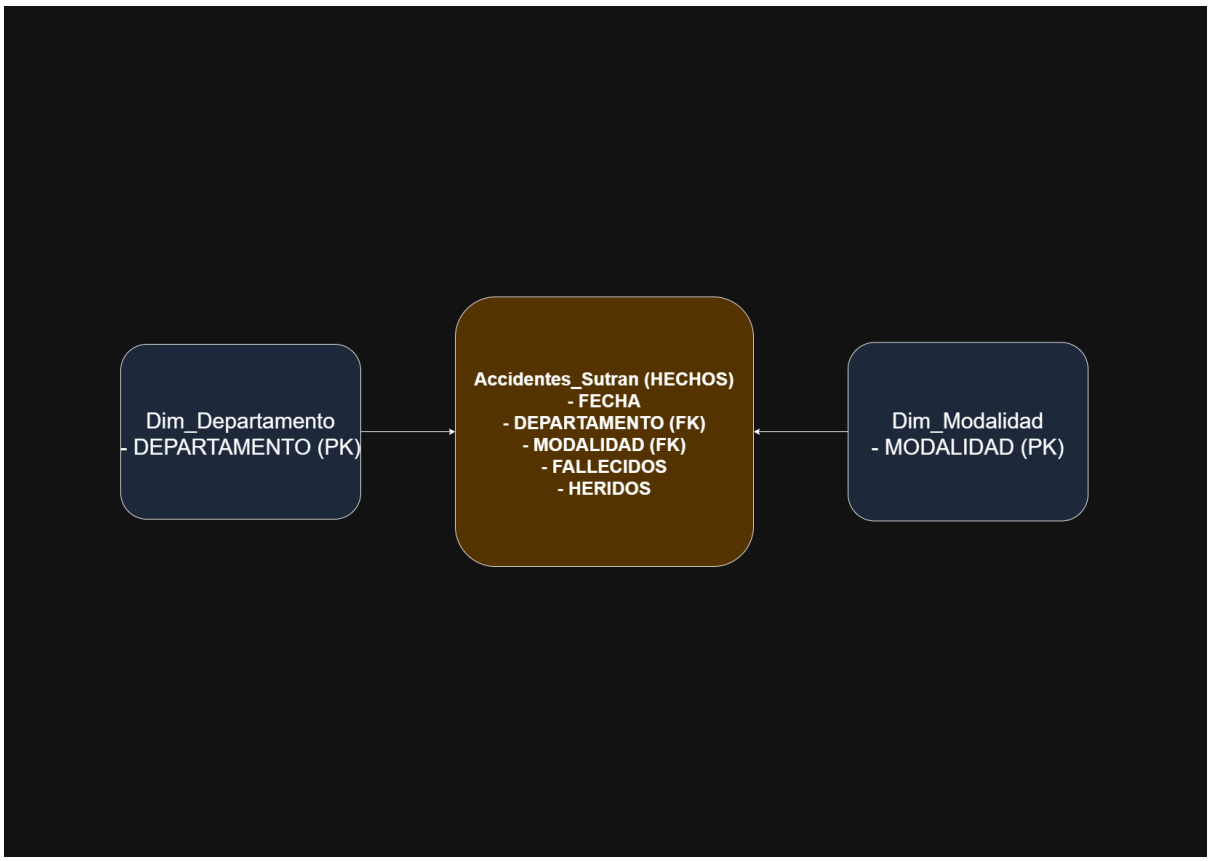


- **Verificación del tercer KPI**



DISEÑO SIMPLE DEL MODELO DE DATOS PARA ANÁLISIS

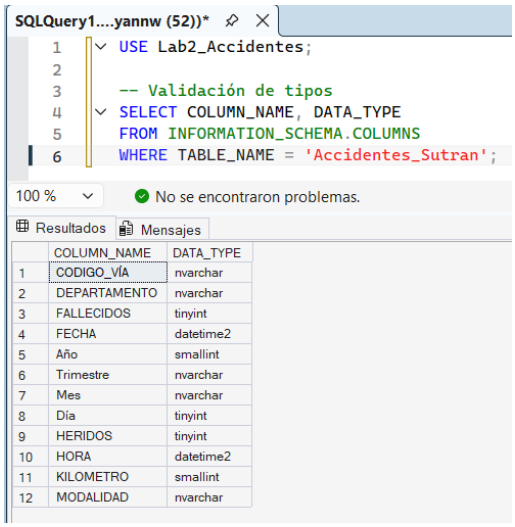
Diseñar un modelo estrella básico (hechos y dimensiones)



VALIDAR RESULTADOS:

- **Validación de coherencia de tipos:**
  "Se verificó mediante SQL (*INFORMATION_SCHEMA.COLUMNS*) la coherencia de los tipos de datos: **FECHA** y **HORA** como *datetime2*, **FALLECIDOS** y **HERIDOS** como *tinyint* (enteros), y **DEPARTAMENTO**, **MODALIDAD** y **CODIGO_VÍA** como *nvarchar* (texto).

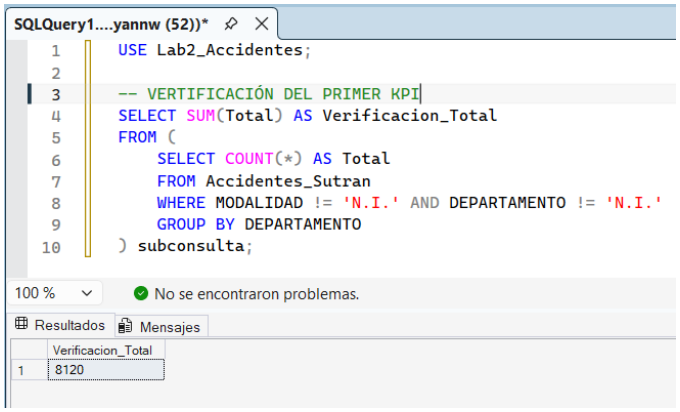
  Para optimizar el modelo en Power BI y Power Query, se corrigió la FECHA de texto a formato *Date*, la HORA de nulo/error a *Time*, y se limpiaron los espacios y mayúsculas en los campos de texto. Como resultado de garantizar las columnas 'FALLECIDOS' y 'HERIDOS' como números enteros, ahora es posible ejecutar funciones de agregación matemática (SUM) en SQL sin errores de sintaxis, mientras que la estandarización del texto permite realizar agrupaciones (GROUP BY) exactas."

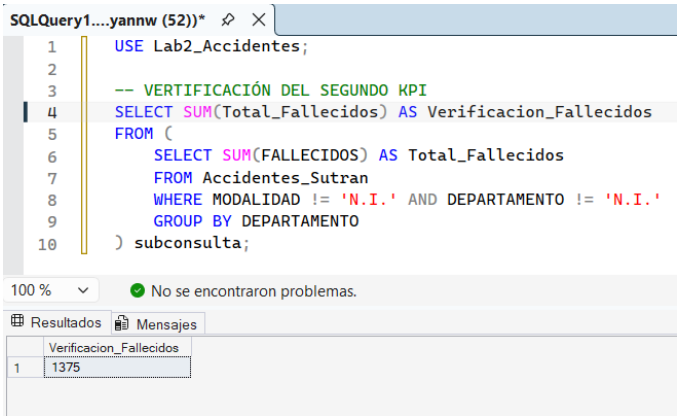


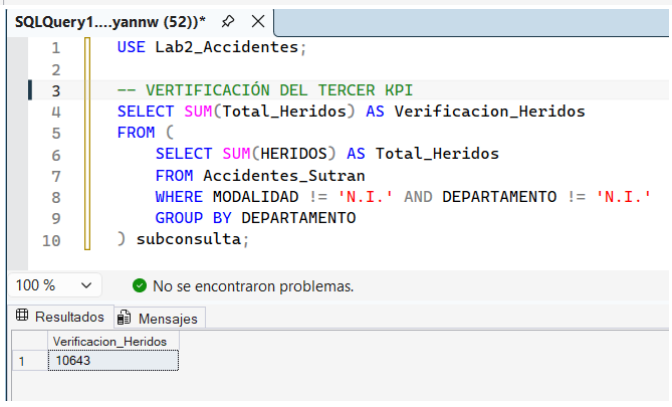
- **Validación de totales:**
  El dataset final cuenta con **8,120 registros limpios**, sobre los cuales se calcularon los siguientes indicadores:

  KPI 1: 8,120 accidentes.
  KPI 2: 1,375 fallecidos.
  KPI 3: 10,643 heridos.

- **Validación de Integridad:**
  > Se comprobó exitosamente la exactitud de estos KPIs utilizando dos métodos distintos. Al cruzar el cálculo general frente a la suma de los subtotales agrupados por departamento (evidenciado en los scripts de la sección anterior), las cifras coinciden con exactitud. Esto garantiza que la estructura es sólida y no hubo pérdida de datos durante las operaciones de `JOIN`.







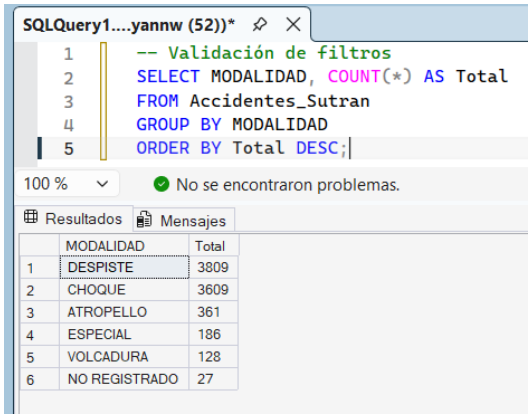
- **Validación de filtros:**

  Se identificaron 27 registros con valor N.I. (No Identificado) en la columna MODALIDAD, equivalente al 0.66% del total de 8,120 registros. Estos registros fueron tratados de manera distinta según la herramienta utilizada:

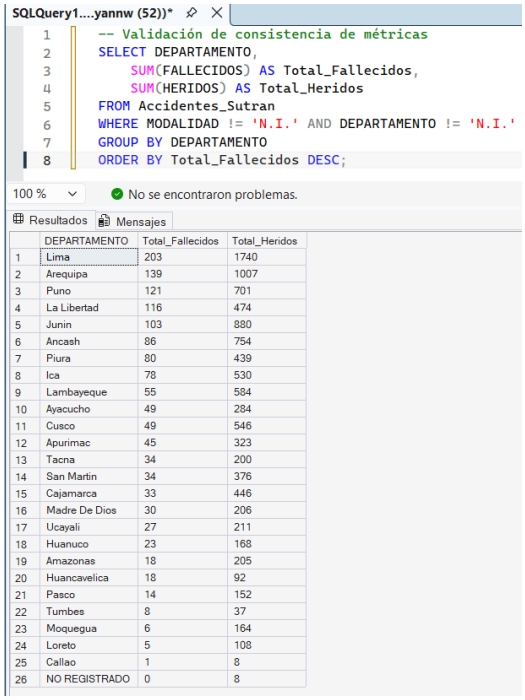
  En **Power BI** (etapa de limpieza), los valores N.I. fueron reemplazados por "NO REGISTRADO" mediante la función ReplaceValue en Power Query. Esta decisión se tomó para mantener la trazabilidad del dato original, es decir, no eliminar el registro sino etiquetarlo correctamente para identificarlo como una limitación del dataset.

  En **SQL** (etapa de análisis), estos registros fueron excluidos del cálculo de KPIs y consultas mediante la cláusula `WHERE MODALIDAD != 'N.I.' AND DEPARTAMENTO != 'N.I.'`. Esta exclusión se justifica porque representan menos del 1% del total y su inclusión no aportaría valor analítico al no tener una categoría definida.

  Esta diferencia de tratamiento entre herramientas es intencional: Power BI conserva el dato para evidenciar la calidad del dataset, mientras que SQL lo filtra para garantizar la precisión de los indicadores calculados.



- **Validación de consistencia de métricas:**
  Se garantizó la integridad de la información confirmando que el conteo de filas en la tabla de hechos es directamente proporcional a los registros del dataset original, sin presentar valores negativos, nulos ni atípicos en las métricas de Fallecidos, Heridos o Kilómetros. La consistencia se validó mediante el cuadre de totales globales frente a la suma por departamentos, donde **Lima** destaca con 203 fallecidos y 1,740 heridos. Este resultado no solo es matemáticamente exacto, sino también coherente con la densidad poblacional de la región.



```
SQLQuery1....yannw (52))*
1  -- Validación de consistencia de métricas
2  SELECT DEPARTAMENTO,
3      SUM(FALLECIDOS) AS Total_Fallecidos,
4      SUM(HERIDOS) AS Total_Heridos
5  FROM Accidentes_Sutran
6  WHERE MODALIDAD != 'N.I.' AND DEPARTAMENTO != 'N.I.'
7  GROUP BY DEPARTAMENTO
8  ORDER BY Total_Fallecidos DESC;
```

100 % — No se encontraron problemas.

Resultados | Mensajes

	DEPARTAMENTO	Total_Fallecidos	Total_Heridos
1	Lima	203	1740
2	Arequipa	139	1007
3	Puno	121	701
4	La Libertad	116	474
5	Junin	103	880
6	Ancash	86	754
7	Piura	80	439
8	Ica	78	530
9	Lambayeque	55	584
10	Ayacucho	49	284
11	Cusco	49	546
12	Apurimac	45	323
13	Tacna	34	200
14	San Martin	34	376
15	Cajamarca	33	446
16	Madre De Dios	30	206
17	Ucayali	27	211
18	Huanuco	23	168
19	Amazonas	18	205
20	Huancavelica	18	92
21	Pasco	14	152
22	Tumbes	8	37
23	Moquegua	6	164
24	Loreto	5	108
25	Callao	1	8
26	NO REGISTRADO	0	8

- **Motivos de decisiones de limpieza/transformación:**
  La etapa de limpieza y transformación fue clave para que el dataset pase de tener formatos desordenados a estar listo para analizarse sin errores. Corregir FECHA y HORA, reemplazar nulos y ordenar los textos permitió que tanto en SQL como en Power BI se puedan hacer sumas, filtros y agrupaciones sin problemas. Esto demuestra que, antes de analizar, primero es necesario asegurar que los datos estén bien estructurados desde el inicio, especialmente cuando provienen de SUTRAN.

CONCLUSIONES

Al realizar los JOIN y las consultas con GROUP BY, y verificar los tipos de datos con INFORMATION_SCHEMA.COLUMNS, se pudo confirmar que las tablas se integraron correctamente y que no hubo pérdida de información. Que los totales generales coincidan exactamente con los subtotales por departamento demuestra que el modelo construido es consistente y confiable para calcular los indicadores.

El manejo de los valores “N.I.” fue una decisión técnica importante. En Power BI se mantuvieron como “NO REGISTRADO” para mostrar la calidad del dato, mientras que en SQL se filtraron para no afectar los KPIs. Este criterio ayudó a mantener un equilibrio entre trazabilidad y precisión, y junto con el modelo estrella, permitió obtener resultados coherentes con la realidad de los accidentes analizados.

BIBLIOGRAFÍAS

- Superintendencia de Transporte Terrestre de Personas, Carga y Mercancías. (2024). *Accidentes de Tránsito en Carreteras* [Conjunto de datos]. Plataforma Nacional de Datos Abiertos. https://www.datosabiertos.gob.pe/dataset/accidentes-de-tránsito-en-carreteras